Лекция 7

# Small string optimization

• Короткие строки храним в самой структуре enum { STRING OPT SIZE = 8 }; struct String size t size; union char \*str; char data[STRING OPT SIZE];

# Функция realloc

- Определена в <stdlib.h>
  void \*realloc(void \*ptr, size\_t newsize);
- Изменяет размер ранее выделенного блока ptr, возвращает адрес нового местоположения
- ptr может остаться на своем месте, но может быть и перемещен
- Если ptr перемещен, ptr разыменовывать нельзя
- Если не хватает памяти, возвращается NULL, ptr остается сохранным
- Если ptr == NULL, работает как malloc
- Если newsize == 0, работает как free

# Vector implementation

- reserved сколько памяти выделено
- size сколько памяти используется
- data данные
- При полном использовании выделенной памяти она расширяется в С раз с помощью realloc: C = 2 или C = 3/2 или другое

#### Vector vs List

- Вектор
  - (+) расположен в памяти последовательно
  - (+) оптимальнее использует кучу
  - (?) вставка и удаление из середины за O(n)

•

- Список предпочтительнее при больших размерах одного элемента и добавлении/удалении из середины
- По умолчанию следует использовать вектор
- https://isocpp.org/blog/2014/06/stroustrup-lists

# Floating Point

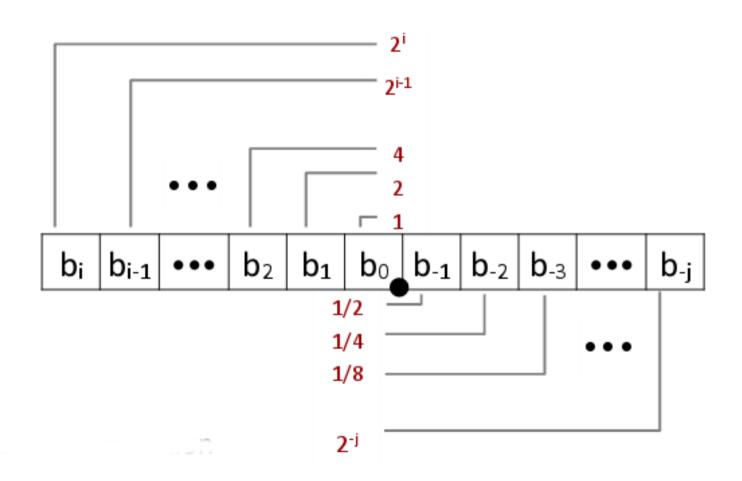
- Fixed point
- IEEE 754
- Операции с плавающей точкой

•

 http://www.cs.cmu.edu/afs/cs/academic/class/15 213-f15/www/lectures/04-float.pdf

# Фиксированная точка (fixed point)

• Представление дробных чисел



# Представление fixed point

- Фиксированное число бит для целой и дробной части
- Рассмотрим пример: 4 бита целая часть, 4 бита дробная часть
  - 1 → 00010000₂ (первые 4 бита (старшие) целая часть, младшие 4 бита дробная)
  - $-2.5 \rightarrow 00101000_{2}$
  - $-5.6875 \rightarrow 01011011_2$

# Преобразование из десятичной записи

- Не всегда преобразование может быть выполнено точно
  - -10 = 2 \* 5
  - 1/5 (0.2) бесконечная периодичная двоичная дробь: 0.001100110011[0011]..
  - 00000011₂ → 0.1875: ошибка = 0.0125
  - $-0.1_{10} = 0.0001100110011[0011]..$
  - 00000010₂ → 0.125: ошибка 0.025
  - 00000001₂ → 0.0625: ошибка 0.0375 хуже чем 0.025
  - 00000001₂ → 0.0625 вес младшего разряда, ошибка преобразования не превышает половины веса младшего разряда (0.03125)

# Операции с фиксированной точкой

- Сложение, вычитание как целые числа
- Умножение:
  - Умножаем как целые числа, получаем 16-битный результат
  - 0010.0110 \* 0100.0010 = 1001.11001100
     округляем до 1001.1101
  - Точный результат: 9.796875, округленный: 9.8125, ошибка: .015625

# Деление с фиксированой точкой

- 0100.0010 / 0010.0110
  - Деление как целые даст только целую часть

  - Делим как целое:  $16896 / 38 = 444 = 1101111100_2$
  - Ставим точку на свое место и округляем 110111100<sub>2</sub> → 1.10111100<sub>2</sub> → 1.1100<sub>2</sub> = 1.75
  - Точные вычисления: 4.125 / 2.375 = 1.73684210...
  - Ошибка: 0.01315789...

# Округление (rounding)

Значение	1.40	1.60	1.50	2.50	-1.50
K нулю (towards 0)	1	1	1	2	-1
Вниз (-∞)	1	1	1	2	-2
Вверх (+∞)	2	2	2	3	-1
К ближайшем у целому вверх	1	2	2	3	-1
Ближайшее четное (умолчанию)	1	2	2	2	-2

# Округление к ближайшему четному

- Статистически несмещенное (прочие способы округления статистически смещены)
  - При суммировании накапливается систематическая ошибка
- При применении к другим десятичным/битовым позициям:
  - Когда ровно между двумя возможными значениями округляем к четной последней цифре:

```
7.8949999 7.89(Less than half way)
7.8950001 7.90(Greater than half way)
7.8950000 7.90(Half way—round up)
7.8850000 7.88(Half way—round down)
```

# Округление в fixed point

- Четное младший значащий бит = 0
- "Half-Way" биты справа от позиции округления равны 100000...
- Примеры (два знака после "."):
  - $-2.09375 = 10.00011_2 \rightarrow 10.00 = 2 down$
  - $-2.1875 = 10.00110_2 \rightarrow 10.01 = 2.25 up$
  - $-2.875 = 10.11100_2 \rightarrow 11.00 = 3 up$
  - $-2.625 = 10.10100_2 \rightarrow 10.10 = 2.5 down$

# IEEE Floating Point

- Стандарт IEEE 754
  - 1985 год, до этого форматы производителей обрудования
  - Поддерживается в основных ЦП
- Появление обусловлено требованиями числовых расчетов
  - Стандарт для переполнений, антипереполнений, округления
  - Трудно реализуется аппаратно
    - Gcc поддерживает -ffast-math и прочие флаги

# Представление чисел

Числовая форма:

$$(-1)^{s} M 2^{E}$$

- Sign bit s определяет положительное или отрицательное число
- Significand M мантисса определяет значение числа [1.0,2.0).
- Exponent E порядок умножает мантиссу на степень 2

#### Encoding

- MSB s бит знака s
- ехр поле кодирует Е (но не равно Е)
- frac поле кодирует М (но не равно М)

S	exp	frac
---	-----	------

#### Точность

■ Single precision (одиночная): 32 bits – тип float

S	exp	frac
1	8-bits	23-bits

Double precision (двойная): 64 bits – тип double

S	exp	frac
1	11-bits	52-bits

Extended precision (расширенная): 80 bits (Intel only)

S	exp	frac
1	15-bits	63 or 64-bits

## Нормализованные значения

- exp != 0...0 && exp != 1...1 (не все нулевые и не все единичные биты)
- Порядок кодируется со смещением: E = exp bias
  - Ехр беззнаковое значение
  - Bias = 2<sup>k-1</sup>, k число бит порядка:
    - Float: 127 (exp: 1..254, E: -126..127)
    - Double: 1023 (exp: 1..2046, E: -1022..1023)
- Мантисса кодируется со "скрытой" ведущей 1: M = 1.xxxxxx<sub>2</sub>
  - Хххххх: биты мантиссы
  - Минимальное значение: frac = 0..0 (M = 1.0)
  - Максимальное значение: frac = 1..1 (M = 2 eps)

# Пример

$$v = (-1)^s M 2^E$$
  
E = Exp - Bias

- Значение: float F = 15213.0
  - $-15213_{10} = 11101101101101_2 = 1.1101101101101_2 \times 2^{13}$
- Мантисса:

$$M = 1.1101101101101_2$$

• Порядок:

E = 13

Bias = 127

 $Exp = 140 = 10001100_2$ 

- Результат
- 0 10001100 11011011011010000000000

# Денормализованные значения

• Условие: exp = 0..0 (все нулевые биты)

$$v = (-1)^s M 2^E$$
  
 $E = Exp - Bias$ 

- Порядок: E = 1 Bias
- Мантисса кодируется со "скрытым" 0: M = 0.xxxxx<sub>2</sub>
  - Ххххх биты мантиссы
- Случаи:
  - Exp = 0..0, frac = 0.0
    - Представление 0
    - Поддерживается знак нуля (0.0 и -0.0)
    - Значение 0.0 все нулевые биты
  - Exp = 0..0, frac != 0..0 (ненулевые биты мантиссы)
    - Самые близкие к 0 числа
    - На равном расстоянии друг от друга

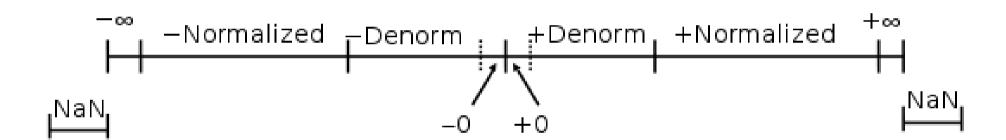
# Специальные значения

Exp = 1..1 (все единичные биты)

- $v = (-1)^s M 2^E$ E = Exp - Bias
- Exp = 1..1, frac = 0..0 (все нулевые биты)
  - Представляет бесконечное значение
  - Для операций, результат которых переполняется
  - Сохраняет знак
  - Примеры:  $1.0/0.0 = -1.0/-0.0 = +\infty$ ,  $1.0/-0.0 = -\infty$
- Exp = 1..1, frac != 0..0 (ненулевые биты)
  - Нечисло (Not-a-number NaN)
  - Для случаев, когда числовой результат не существует
  - Примеры: sqrt(-1), ∞ ∞, ∞ × 0

# Визуализация значний

• Визуализация на числовой прямой



# Распределение значений

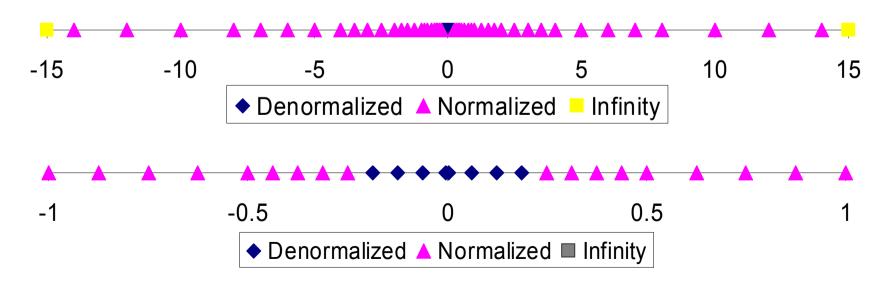
• 6-битовый формат типа IEEE

•

•

S	ехр	frac
1	3-bits	2-bits

• Значения "уплотняются" к нулю



# Операции с плавающей точкой

- Сначала вычисляется точный результат
- Потом помещается в требуемую точность
  - Возможное переполнение (+INF или -INF) если порядок слишком велик
  - Округление чтобы поместить в мантиссу

## **FP Multiplication**

- $-(-1)^{s1} M1 2^{E1} \times (-1)^{s2} M2 2^{E2}$
- Exact Result: (-1)<sup>s</sup> M 2<sup>E</sup>
  - Sign S: s1 ^ s2
  - Significand M: M1 x M2
  - Exponent E: E1 + E2

#### Fixing

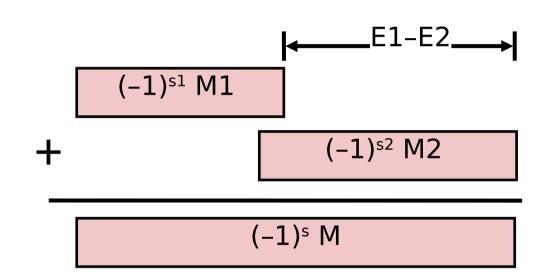
- If M ≥ 2, shift M right, increment E
- If E out of range, overflow
- Round M to fit frac precision

#### Implementation

Biggest chore is multiplying significands

### Floating Point Addition

- $\blacksquare$  (-1)<sup>s1</sup> M1 2<sup>E1</sup> + (-1)<sup>s2</sup> M2 2<sup>E2</sup>
  - Assume E1 > E2
- Exact Result: (-1)<sup>s</sup> M 2<sup>E</sup>
  - Sign S, significand M:
    - Result of signed align & add
  - Exponent E: E1



Get binary points lined up

- Fixing
  - If M ≥ 2, shift M right, increment E
  - ■if M < 1, shift M left k positions, decrement E by k
  - Overflow if E out of range
  - Round M to fit frac precision

# Свойства операций

 Сложение неассоциативно: (a+b)+с != a+ (b+c):

```
(3.14+1e10)-1e10 = 0, 3.14+(1e10-1e10) = 3.14
```

• Умножение неассоциативно:

```
(1e20*1e20)*1e-20=inf, 1e20*(1e20*1e-20)=1e20
```

• Умножение недистрибутивно: a\*(b+c) != a\*b+a\*c

```
1e20*(1e20-1e20)=0.0, 1e20*1e20 - 1e20*1e20 = NaN
```