

Лекция 31
Модель памяти C/C++
(C11+, C++11+)

Атомарность работы с памятью

- Операции чтения или записи для натурально выравненных значений размером не больше машинного слова — атомарны на практике.
- Но стандарты Си и Си++ этого не гарантируют!
- Операции с данными размера больше машинного слова НЕ АТОМАРНЫ.
- Операции чтение-модификация-запись — НЕ АТОМАРНЫ (++ , += , и аналогичные).

Data race

- Data race — ситуация в многопоточной программе, когда
 - Два потока одновременно работают с одной и той же переменной (ячейкой памяти)
 - Один из потоков пишет в эту ячейку памяти
- Практически всегда data race — это ошибка в программе!
- Data Race — это UNDEFINED behaviour, т. е. компилятор и среда выполнения вольны делать что угодно
- Работа с atomic-переменными не приводит к Data Race

Атомарные переменные C++11

- `<atomic>`
- `std::atomic<T>`
- Специализация возможна для любого типа, но не все специализации будут lock-free
- Гарантировано только `std::atomic_bool` будет lock-free
- `std::atomic_bool`, `std::atomic_char`, ...
- Определен набор методов и перегружены основные операции

Атомарные переменные C11

- `<stdatomic.h>`
- `_Atomic`
`_Atomic int x;`
`int * _Atomic y;`
- `atomic_bool`, `atomic_int` ...
- Только `atomic_bool` гарантируется lock-free
- Поддерживаются основные операции (`=`, `+=`, ...)

Атомарные переменные

- Параллельная работа с атомарными переменными
 - Атомарна
 - Свободна от data race
- Если переменная используется из нескольких нитей одновременно (не в критической секции), она должна быть `atomic`
- Lock-free – для работы с переменной используются специальные инструкции процессора
- Иначе может использоваться мьютекс

Модель памяти

- Компилятор может переставлять операции работы с памятью, при условии, что сохраняется семантика ОДНОПРОЦЕССНОЙ программы.
 - $x = 1; y = 2;$ - переставить можно
 - $x = 1; y = x + 1;$ - переставить нельзя
- При выполнении программы процессор может выполнять спекулятивные загрузки из памяти, самостоятельно переставлять операции
- Процессор реализует протокол поддержки когерентности кешей

Модель памяти

- Минимальные требования к перестановкам операций с памятью между разными нитями задаются *моделью памяти*.
- Модель памяти — это свойство процессорной архитектуры.
- *Сильная модель памяти* (strong memory model) требует, что если одно процессорное ядро выполняет запись в память в определенной последовательности, все другие процессорные ядра видят изменения значений в памяти в той же самой последовательности (x86).
- В *слабой модели памяти* процессор может переставлять порядок и операций чтения, и операций записи при условии, что такие перестановки не изменяют результат вычисления программы состоящей из одной синхронно выполняющейся нити (ARM).

Наблюдаемый порядок операций

- Наблюдаемый порядок изменения значений в памяти в одной нити может отличаться от наблюдаемого порядка изменения значений в памяти в другой нити.

```
y = 0;                                if (y == 2) {  
x = 0;                                z = x;  
// ...                               }  
x = 1;  
y = 2;  
// ...  
x = 3;
```

- Во второй нити *z* может принимать значения 0, 1 или 3!

memory_order

- Операция с `_Atomic` окружена операциями с обычными (не атомарными) переменными
- `memory_order` определяет, какие ограничения накладываются на перестановки обычных операций вокруг атомарной операции

memory_order

- memory_order_relaxed — самый слабый
- memory_order_acquire
- memory_order_release
- memory_order_acq_rel
- memory_order_seq_cst — самый сильный

memory_order_relaxed

- `memory_order_relaxed` - самый слабый порядок работы с памятью. Операция с атомарной переменной в этом режиме предполагает только атомарность и не дает никаких гарантий сохранения порядка записей в память или чтения из памяти для операций вокруг данной, если только они не выполняются с более сильным порядком работы с памятью.

Acquire/release

- В нити A выполняется сохранение в память в режиме `memory_order_release`
- В нити B выполняется чтение из той же самой переменной в режиме `memory_order_acquire`.
- Все записи в память (и обычные неатомарные, и в режиме `memory_order_relaxed`), которые с точки зрения нити A выполняются раньше атомарной операции сохранения в память гарантированно становятся видимыми в нити B.
- После выполнения атомарной загрузки из памяти в нити B она гарантированно увидит все, что нить A записала в память.

Sequentially consistent

- Последовательно консистентный режим работы — самый строгий.
- Атомарная операция, выполняющаяся в режиме `memory_order_seq_cst`:
 - является и `release`, и `acquire` операцией
 - все нити видят все операции, выполненные в этом режиме, в одном и том же порядке.
- Этот режим действует по умолчанию для атомарных операций.

Операции с atomic

- Загрузка (load)
- Сохранение (store)
- Обмен (exchange)
- Сравнение-обмен (compare_exchange)
- Арифметика (fetch_add, fetch_sub, ...)
- Барьер

Atomic и volatile

- Чтение/запись volatile переменной НЕ ОБЯЗАНЫ быть атомарными
- Влияние операций с volatile на окружающие операции с обычными переменными не определено (компилятор может переставлять как угодно)
- Data Race на volatile — это также UB
- Volatile не предназначен для использования в параллельных программах