Лекция 9 Оперативная память

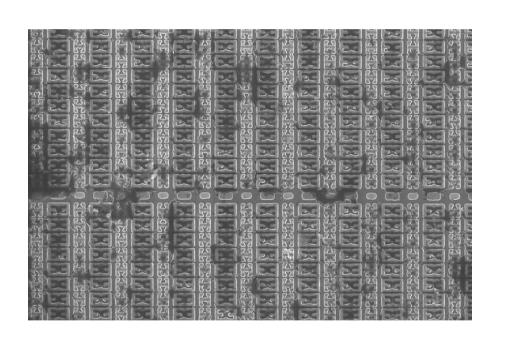
Типы ОЗУ

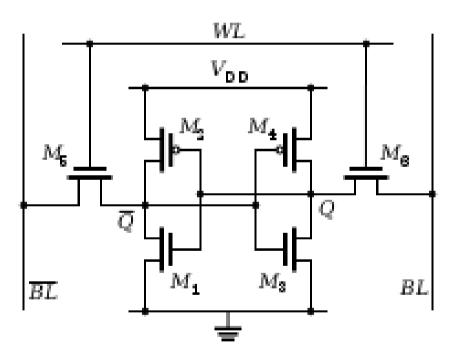
- Статическая память произвольного доступа (SRAM)
- Динамическая память произвольного доступа (DRAM)

Временные характеристики ОЗУ

- Время чтения время от начала операции чтения до появления значения на выходе
- Время цикла время от начала операции чтения до готовности к следующей операции

Внешний вид





Принцип действия

- Транзисторы М1, М2, М3, М4 два инвертора, "навстречу" друг другу: два стабильных состояния (0 и 1), пока подключено питание на Vdd
- В пассивном (stand-by) состоянии ток практически не протекает
- Транзисторы М5 и М6 подключают ячейку к линии данных BL
- Одновременно считываются/устанавливаются BL и #BL (повышается надежность)

Статическая ППД

• 6 транзисторов (существуют схемы 4-10 тр.)

WL

BL

- Время чтения: ~1 такт
- Время цикла: ~1 такт
- Время записи: ~2 такта
- Тактовая частота любая

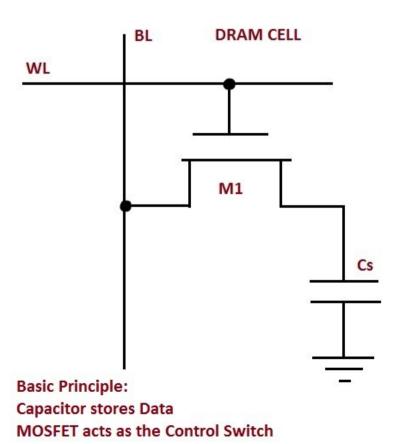
• Vdd – питание, WL – активация — —

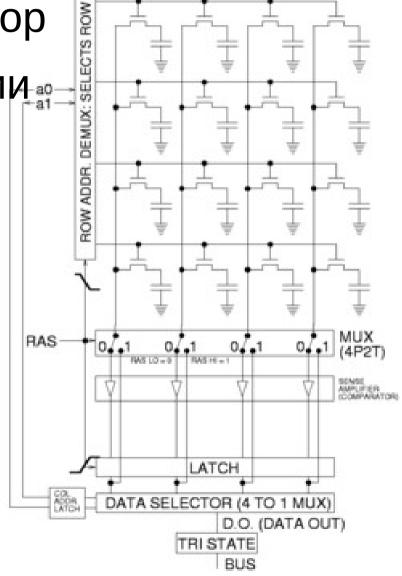
BL - данные

Динамическая ППД

• 1 транзистор + 1 конденсатор

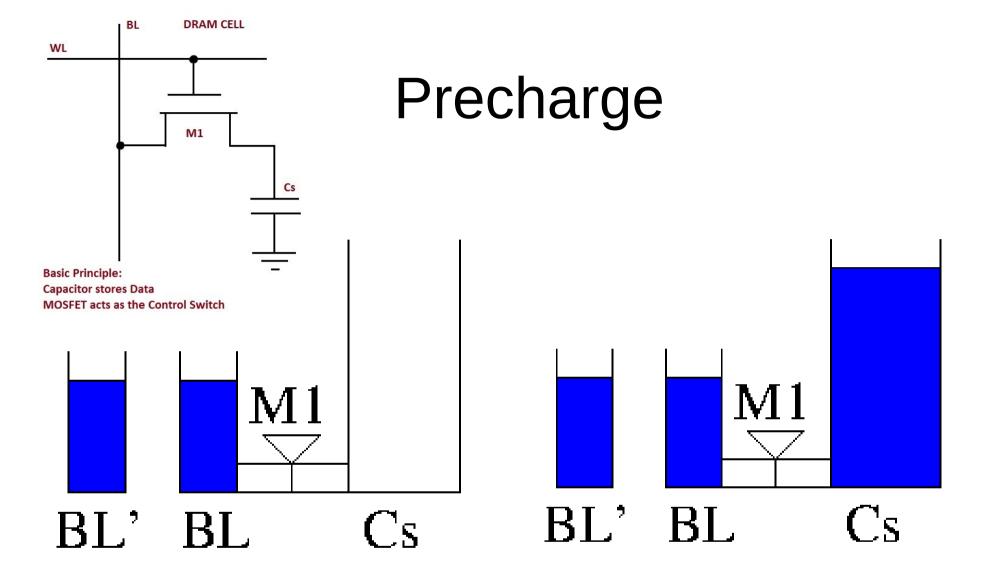
• Необходимость регенерации ап





Чтение из DRAM (1)

- Precharge на линии BL и BL' подается напряжение 0.5V (половина рабочего)
- Линии обладают достаточной емкостью для накопления некоторого заряда
- Линия BL подключена к ячейкам через управляющий транзистор
- Линия BL' имеет точно такую же емкость, как и BL, но не подключена (референсная)



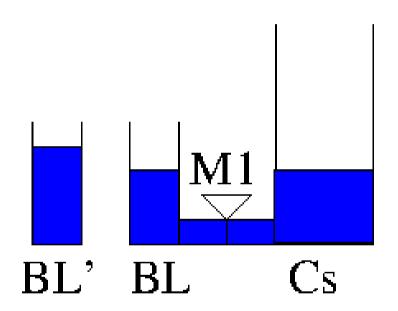
Ячейка содержит 0

Ячейка содержит 1

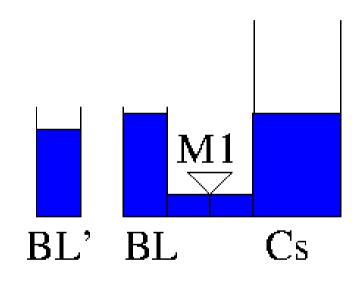
Чтение из DRAM (2)

- На нужную горизонтальную линию (ROW)
 подается напряжение логической 1,
 открываются ВСЕ транзисторы в ряду (Row
 Select RAS)
- Все ячейки в одном ряду соединяются с соответствующими линиями BL
- Напряжения в линиях BL чуть уменьшаются или чуть увеличиваются в зависимости от значений в ячейках

Reading



Ячейка содержит 0



Ячейка содержит 1

Чтение из DRAM (3)

- Напряжение на BL и BL' сравнивается и в каждом столбце фиксируется 0 или 1
- Строка фиксируется (LATCH)
- Заряд в подключенных ячейках обновляется (refresh)
- Из строки выбираются нужные биты (Column Select CAS)
- Строка закрывается (транзисторы отключаются)
- Затем снова начинается Precharge и цикл чтения повторяется

Алгоритм чтения из DRAM

- ROW SELECT на нужную строку подается напряжение V, транзисторы открываются
- Напряжение вертикальной линии BL слегда изменяется, разница BL и BL' усиливается дифференциальным усилителем одновременно считывается и фиксируется (latch) целая строка
- COL SELECT выборка нужных битов из выбранной строки
- После выборки нужных бит строка закрывается
- PRECHARGE на все битовые (вертикальные) линии В+ и В- подается напряжение 0.5 V (от рабочего)

Обновление DRAM

- Распознаваемый «единичный» заряд в конденсаторе может держаться до 1-10с
- Обновление чтение и запись обратно каждой ячейки
- Современные поколения DRAM обновляют каждую ячейку каждые 64мс
- Во время обновления память недоступна процессору
- Накладные расходы на обновление примерно 1% времени

Модификации DRAM

- SDRAM (synchronuous DRAM) использует тактовые импульсы для синхронизации. Все временные характеристики задаются в тактах.
- DDR SDRAM (Double Data Rate) передача/прием данных дважды за такт
- DDR, DDR2, DDR3

Memory Timings

- CAS Latency (Tcl) время между выдачей адреса столбца и получением данных
- RAS to CAS Delay (Trcd) время между выдачей адрес строки и адреса столбца
- Row Precharge Time (Trp) время между выдачей команды precharge и открытием следующей строки
- Row Active Time (Tras) время между выборкой строки и выдачей команды precharge

•

Row Cycle Time: Trc = Tras + Trp

Производительность памяти

- PC-3200 (DDR-400) 2000
 - 3-4-4-8 (15ns-20ns-20ns-40ns)
- PC2-6400 (DDR2-800) 2003
 - 5-5-5-16 (12.5-12.5-12.5-40)
- PC3-12800 (DDR3-1600) 2007
 - 9-9-9-27 (11.25-11.25-11.25-33.75)

Сравнение скорости ЦП и ОЗУ

- Предположим, тактовая частота процессора
 3.2ГГц
- Тактовая частота ОЗУ 800 МГц (¼ от частоты процессора)
- Время чтения: 72 тактов процессора
- Время цикла: 108 тактов
- С учетом накладных расходов время чтения из ОЗУ: 100 200 тактов процессора

Кэширование

• Кэш (cache) (заначка, тайник) — средство для сглаживания разности скоростей устройств. Некоторая часть данных с медленного устройства помещается в кэш, работающий со скоростью быстрого устройства.

Иерархия памяти



Кеш-память

- Кеш-память имеет смысл, так как программы на практике демонстрирую свойство **локальности**
- Кеш-память не дает улучшения в худшем случае (при случайных обращениях в память)

Свойство локальности

- Временная локальность если программа обращается к некоторой ячейке памяти впервые, велика вероятность того, что скоро обращение к этой ячейке памяти повторится
 - Циклы в коде программы
 - Переменные в памяти
- Пространственная локальность если программа обращается к некоторой ячейке памяти, велика вероятность того, что скоро программа обратится к соседним ячейкам
 - Код программы
 - Массивы/структуры в памяти

Работа кэш-памяти

- Попадание (hit) значение берется из кэша, а не из ОЗУ
- Промах (miss) требуемой ячейки в кэше нет
 - Обязательный промах (ячейка не загружена)
 - Промах из-за размера
 - Промах из-за конфликта (ячейка была в кэше, но оказалась выгруженной)

Промахи в кеше

- Обязательный промах (compulsory miss) ячейка не была загружена в кеш первое обращение к ней в программе
- Промах из-за емкости (capacity miss) размер кеша слишком мал для одновременного хранения используемых данных
- Промах из-за конфликта (conflict miss) нужные данные были в кеше, но оказались выгружены из-за ограниченной ассоциативности

Кэш-память ЦП

- L1 наименьший размер (до 64 KiB), делится на кэш инструкций и данных (L1I, L1D), раздельный для каждого ядра
- L2 средний размер (1МіВ), общая для данных и инструкций, раздельный
- L3 наибольший размер (до 8МіВ), общая для данных и инструкций, общая для всех ядер
- TLB (translation lookahead buffer) для организации виртуальной памяти

Среднее время доступа

- Оценка времени, которое процессор тратит, ожидая данные из памяти
- Для одноуровневого кеша AMAT = $t_c + M_c * t_M$
- t_c время обращения к кешу
- М_с вероятность промаха в кеше
- t_м время обращения к памяти
- Если $t_c = 1$, $M_c = 0.10$, $t_M = 100$, то AMAT = 11

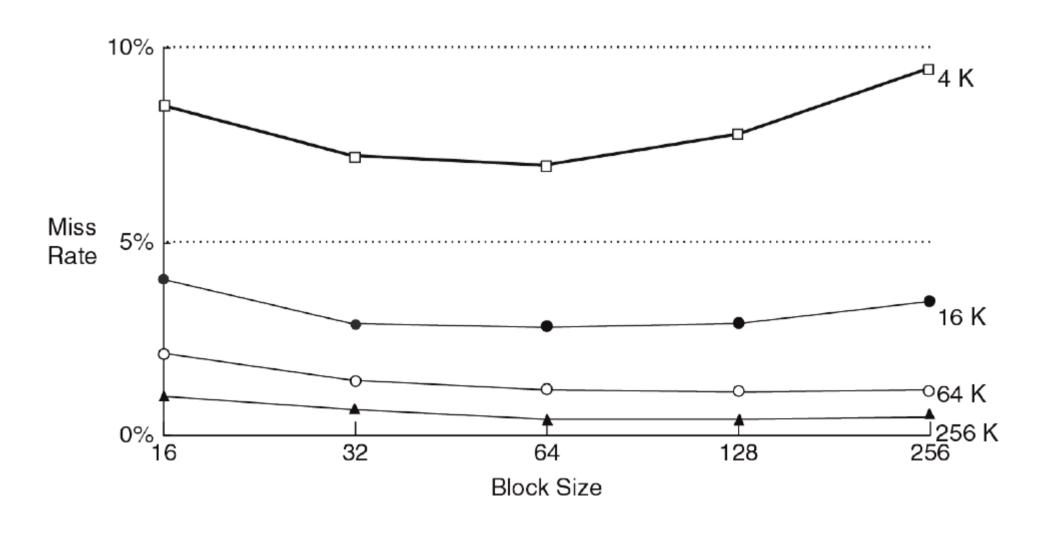
Характеристики кэш-памяти

- Размер
- Время доступа
- Размер ряда (блока) кэша
- Ассоциативность
- Политика записи в основную память
- Политика замещения
- Политика обеспечения когерентности

Размер ряда (блока)

- Cache Line (cache block) единица хранения данных в кеше
- При чтении одного байта из ОЗУ загружается ряд (блок) ячеек
- Типичный размер: 32 или 64 байта

Зависимость от размера блока



Ассоциативность

- Предположим, что кэш позволяет разместить М блоков
- Рассмотрим загрузку блока В из памяти в кэш
- Если блок В может быть размещен в любой ячейке кэша полностью ассоциативный
- Если блок В может быть размещен в одной ячейке **прямое отображение**
- Если блок В может быть размещен в N ячейках кэш N-ассоциативный

Кеш прямого отображения

- Каждый из адресов в ОЗУ отображается в единственную ячейку кеша
- Пусть размер блока 16 байт, размер кеша 256 байт, размер ОЗУ 4 КіВ: в кеше 16 блоков, в ОЗУ 256 блоков
- Адрес в ОЗУ состоит из трех частей (адреса hex): XYZ
 - Х игнорируется при отображении, Ү номер блока, Z
 - смещение в блоке
 - 9А7 адрес отобразится в блок кеша А
 - 2АЗ адрес отобразится в блок кеша А конфликт

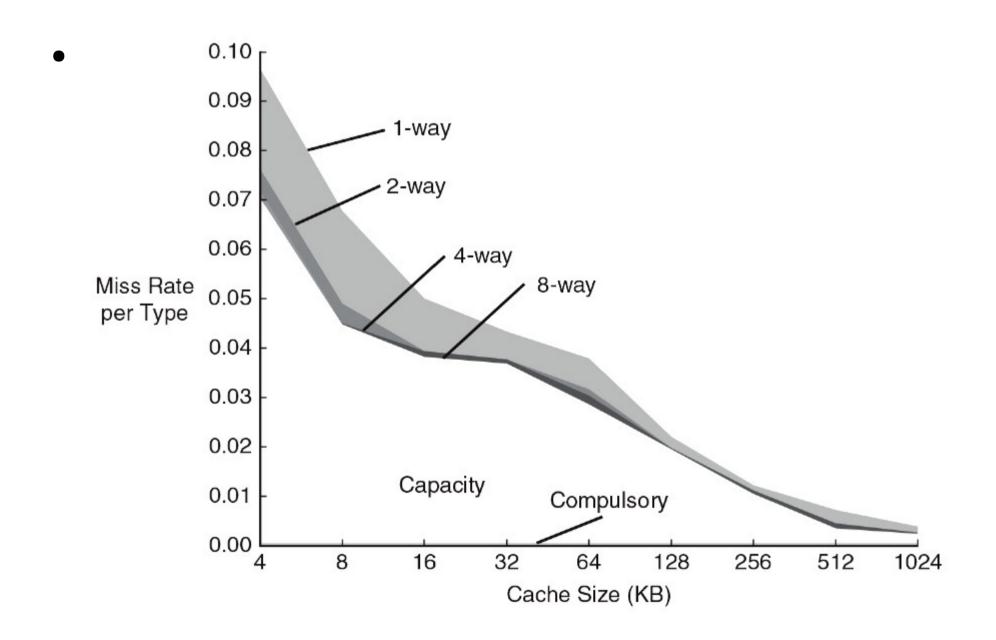
N-ассоциативный кеш

- N-секционный наборно-ассоциативный кеш (N-way set associative cache)
- Кеш делится на наборы, каждый набор содержит N блоков
- Каждый адрес памяти отображается в строго определенный набор, но в наборе может попасть в любой блок

N-ассоциативный кеш

- Пусть размер блока 16 байт, размер кеша 256 байт, размер ОЗУ 4 КіВ: в кеше 16 блоков, в ОЗУ 256 блоков;
- Кеш 4-наборный, каждый набор 4 блока
- Рассмотрим адрес XYZ, Y определяет местоположение в кеше: Y & 3 номер набора; 6 битов адреса (XY >> 2) являются тегом в наборе
- Совпадение части Х в адресах не означает конфликта
- Меньше промахов типа conflict miss

Оценка % промахов на SPEC2000



Политика замещения

- При чтении блока в кеш, когда все позиции на которых может разместиться блок в кеше заняты необходимо выкинуть из кеша один из блоков
- Выбор блока для удаления из кеша определяется политикой замещения (replacement policy)
- Возможные политики замещения:
 - LRU (least recently used) не используемый наиболее давно
 - LFU (least frequently used) используемый наименее часто

Политика записи в основную память

- При выполнении операции записи в ячейку памяти, которая находится в кеше, возможны следующие варианты:
- Модифицировать ячейку в кеше и сразу же выполнить операцию записи в основную память (сквозная запись write-through)
- Модифицировать ячейку в кеше и отметить ее как "грязную" и отложить запись на более удобный момент (отложенная запись – write-back)

Когерентность кеша

- В многоядерных процессах или многопроцессорных системах каждое ядро обладает своими L1 и L2 кешами
- Один и тот же блок основной памяти может находиться в нескольких кешах
- Одно из ядер выполняет модификацию этого блока что делать?
- Стратегии поддержания когерентности:
 - Snooping кеши следят за адресами записи в память
 - Write invalidate модифицированные блоки выбрасываются из "соседних" кешей
 - Write update модифицированные блоки обновляются

Политика включения

- Для многоуровневых кешей:
- Inclusive policy если блок присутствует в кеше Li (L1, L2), он присутствует и в кешах более низкой иерархии
 - Если блок удаляется из кеша более низкой иерархии (associativity miss), он удаляется из кешей иерархии выше
- Exclusive policy блок присутствует только в одном кеше
 - Блок переносится "вверх" или "вниз"
- NINE (non-inclusive non exclusive)