Лекция 41
Управление памятью в ядре ОС

Виртуальная адресация

- Для многопроцессной обработки требуется защита памяти: процесс не должен иметь неавторизованный доступ к памяти других процессов и ядра
- Адреса ячеек памяти данных и программы, используемые в процессе, не обязаны совпадать с адресами в физической памяти (ОЗУ)
- Адреса ячеек памяти для процесса — **виртуальные адреса**
- Адреса ячеек памяти в оперативной памяти — **физические адреса**

Виртуальная адресация (память)

- Программно-аппаратный механизм трансляции виртуальных адресов в физические
- Аппаратная часть — отображение виртуальных адресов в физические в «обычной» ситуации — должно быть очень быстрой, так как необходимо для выполнения каждой инструкции
- Программная часть — подготовка отображения к работе, обработка исключительных ситуаций

Модели виртуальной адресации

- Модель база+смещение
  - Два регистра для процесса: регистр базы (B), регистр размера (Z)
  - Пусть V — виртуальный адрес (беззнаковое значение), если V >= Z — ошибка доступа к памяти, иначе
  - P — физический адрес, P = B + V

Сегментная адресация

- Каждый процесс состоит из нескольких сегментов: сегмент кода, сегмент стека, сегмент данных1, сегмент данных2
- Для каждого сегмента хранятся свои базовый адрес и размер
- У каждого сегмента свои права доступа, например:
  - Код: чтение + выполнение
  - Стек: чтение + запись
- Сегмент может отсутствовать в оперативной памяти и подгружаться по требованию

Страничная адресация

- Все пространство виртуальных адресов разбивается на страницы **равного размера**
- Каждая страница виртуальной памяти отображается на физическую память независимо от других
- Каждая страница имеет права доступа независимо от других страниц
- Страница может быть отмечена как неотображенная или отсутствующая в памяти
- При невозможности аппаратно отобразить виртуальную страницу в физическую — Page Fault

Отображение страниц

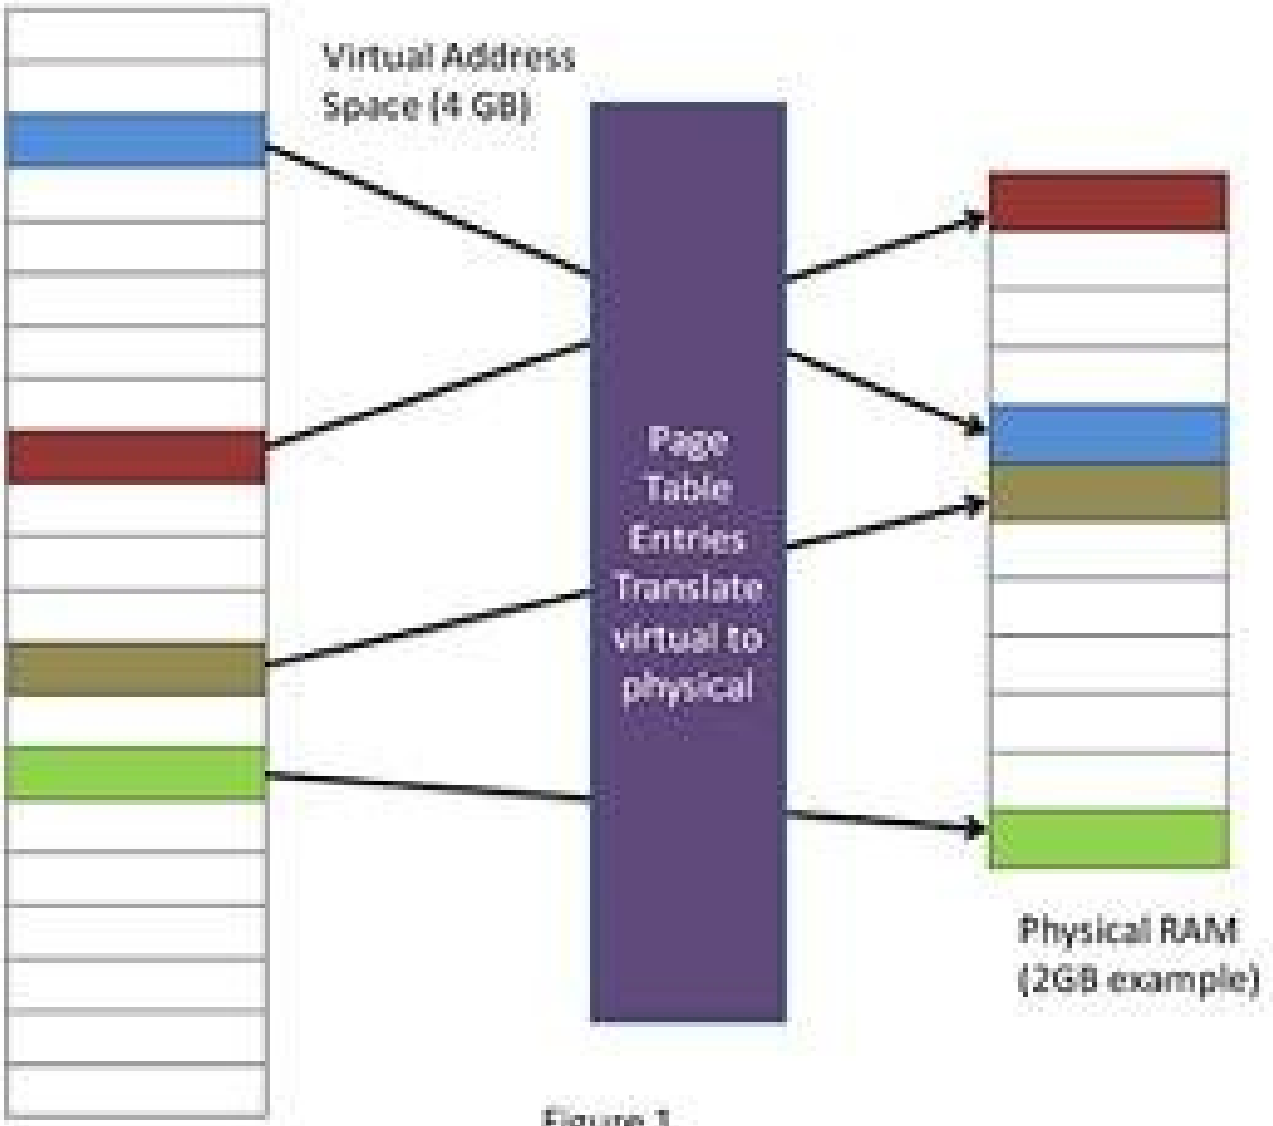

Figure 1

Виртуальный адрес

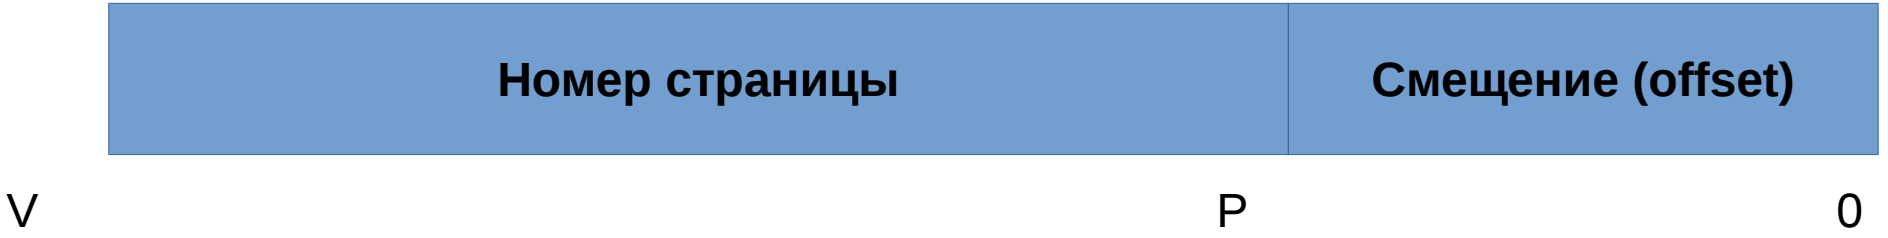

- V — количество бит виртуального адреса
- P — количество бит на смещение в страницу
- (V - P) — количество бит на номер страницы
- Для x86: V = 32, P = 12, V-P = 20
  - Виртуальное адресное пространство 4GiB
  - Размер страницы — 4096 байт (4KiB)
  - 2^20 (~1 Mi виртуальных страниц)

Двухуровневая таблица страниц (x86)

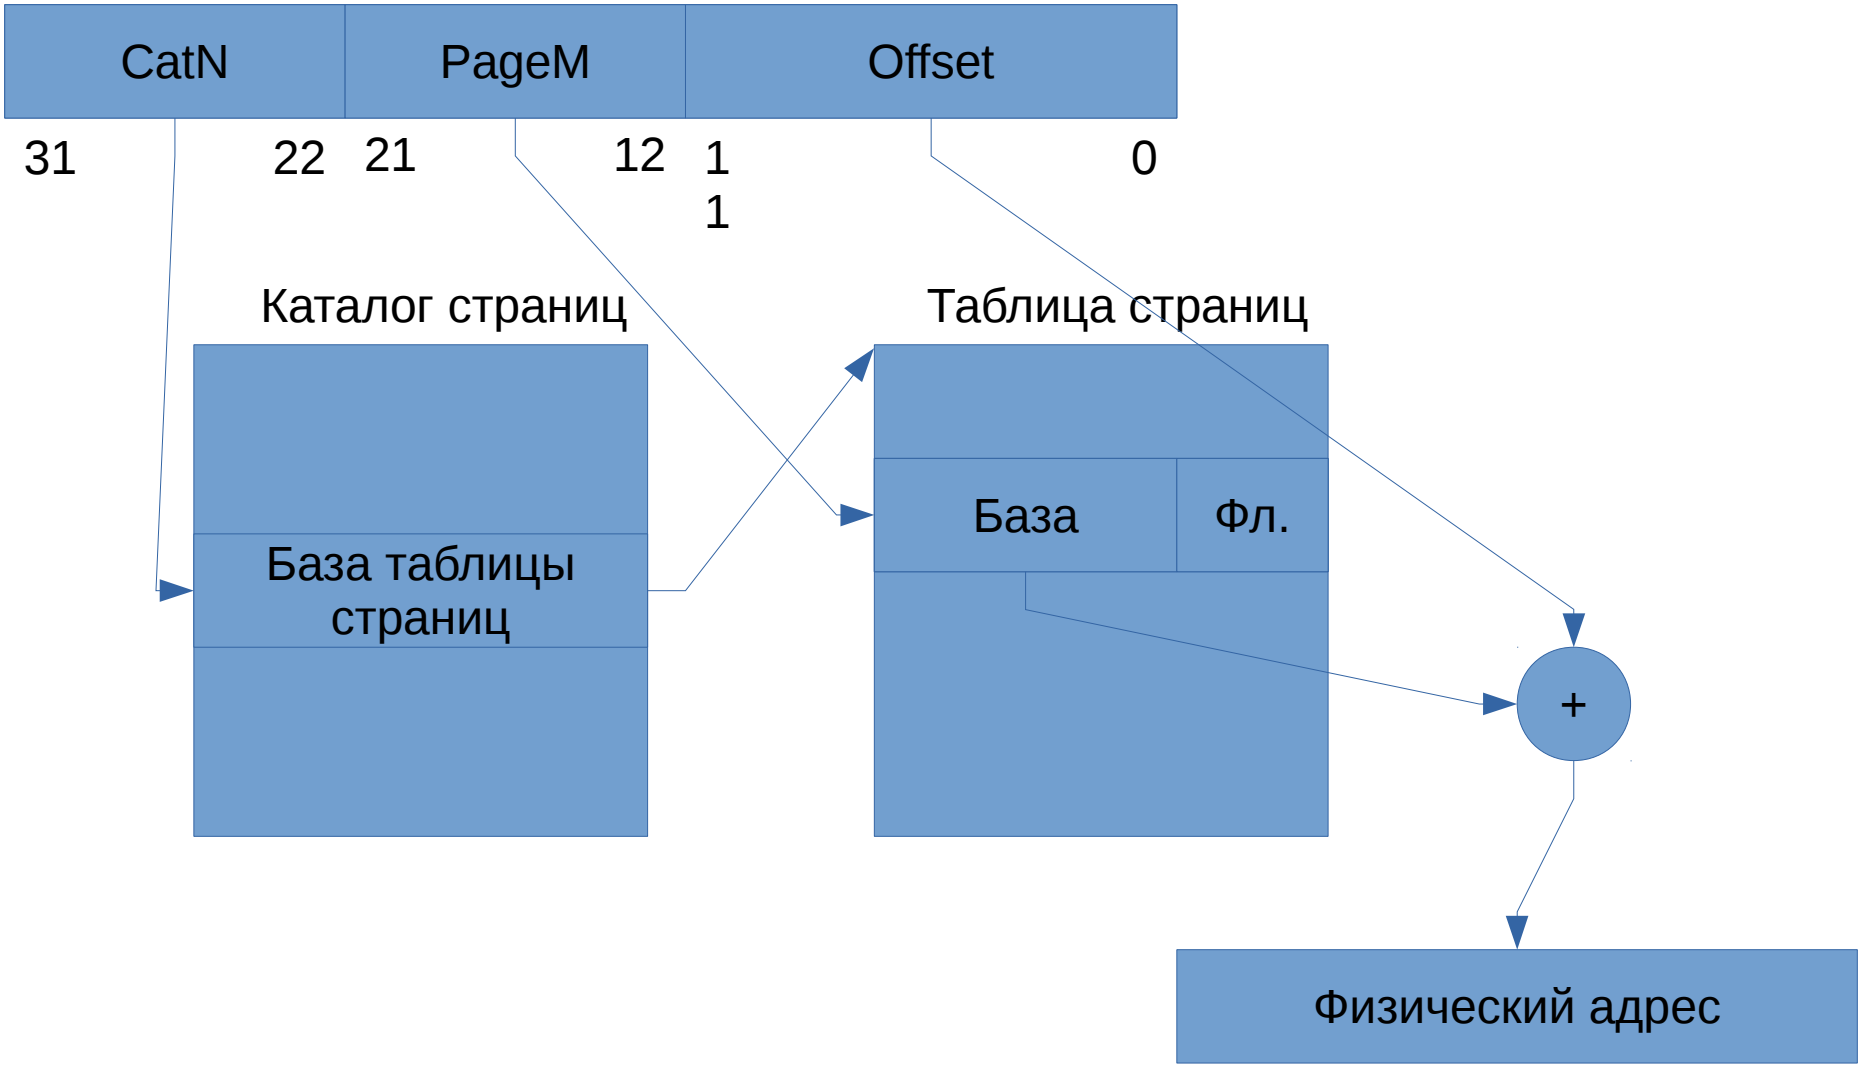

Таблица страниц

- Регистр процессора CR2 указывает на начало каталога страниц
- X86 — двухуровневая таблица страниц, размер страницы — 4KiB, в каталоге страниц 1024 записи, в каждой таблице страниц 1024 записи, одна запись — 4 байта
- X64 — четырехуровневая таблица страниц, размер страницы — 4KiB, в таблице каждого уровня 512 записей, одна запись — 8 байт.

Элемент таблицы страниц (x86)

- P — страница присутствует в ОЗУ
- R — право на запись в страницу
- U — доступна из user-space
- C — кеширование страницы запрещено
- W — разрешена сквозная (write-through) запись
- A — к странице было обращение
- D — (dirty) страница была модифицирована
- G — страница глобальная

Трансляция адресов x86

```
#define PAGE_SIZE  4096
#define TABLE_SIZE 1024
unsigned translate(unsigned va)
{
  unsigned *catalog = CR2;
  unsigned *table = catalog[va >> 22] & -PAGE_SIZE;
  unsigned phys = table[(va >> 12) & (TABLE_SIZE - 1)]
& -PAGE_SIZE;
  return phys + (va & (PAGE_SIZE - 1));
}
```

Доступ к странице

- Если страница отсутствует в ОЗУ (P == 0), обращение к странице → Page Fault
- Если в user-space и U == 0 → Page Fault
- Если записываем в страницу и R == 0 → Page Fault
- Устанавливаем флаг «accessed» (A = 1)
- Если записываем, устанавливаем флаг «dirty» (D = 1)

TLB (Translation Lookaside Buffer)

- Двухуровневая таблица страниц может потребовать 2 вспомогательных обращения к памяти!
- TLB — кэш-память для отображения виртуального адреса в физический
- TLB может быть многоуровневым и разделенным: для Intel Nehalem:
  - 64 записи в L1 DTLB
  - 128 записей в L1 ITLB
  - 512 записей в L2 TLB

PageFault

- Исключение PageFault не обязательно ошибка в программе
- Допустимые ситуации:
  - Страница данных откачана в swap (P == 0)
  - Страница кода не загружена из файла (P == 0)
  - Запись в страницу созданную для copy-on-write (R == 0)
- Обработчик исключения определяет причину PageFault. Если PageFault произошел из-за ошибки, ошибка передается в программу

3G/1G virtual memory split

- Верхний 1GiB адресного пространства процесса содержит страницы, отображенные в режиме U == 0
- Страницы недоступны из user-space, но как только процесс переключается в kernel-space они становятся доступны
- Код и данные ядра отображаются в эту часть адресного пространства
- При переключении контекста (при входе в системный вызов) нет накладных расходов на перезагрузку таблицы страниц
- Из кода ядра непосредственно доступна память процесса (copy_from_user, copy_to_user)

Управление памятью в ядре Linux

Управление физической памятью

- struct page; - дескриптор физической страницы — создается для каждой страницы
- sizeof(struct page) == 32 на x86
- struct page *mem_map; - массив всех физических страниц
- Если размер ОЗУ 4GiB, то массив mem_map займет 32MiB пространства ядра
- Определена в include/linux/mm_types.h

Struct page

- unsigned long flags;
  - PG_locked; - не может быть выгружена
  - PG_error; - I/O error на этой странице
  - PG_referenced; - было обращение к странице
  - PG_uptodate; - содержимое корректно
  - PG_dirty; - требует записи на диск
- struct address_space *mapping;
  - Либо указатель на пространство inode,
  - Либо на anon_vma (для анонимных страниц)

Struct page

- atomic_t _mapcount;
  - Счетчик использований данной физической страницы в PTE (page table entry) виртуального адресного пространства страниц
- atomic_t _count;
  - Счетчик ссылок
- struct list_head lru;
  - Поля prev, next, которые организуют страницы в список LRU
- pgoff_t index;
  - Смещение в отображении mmap
- struct address_space *mapping;
  - Структура, описывающее отображение страницы (inode)

Зоны физической памяти

- Области физической памяти
  - ZONE_DMA — пригодные для DMA
  - ZONE_NORMAL — непосредственно отображенные в виртуальное адресное пространство ядра
  - ZONE_HIGH — динамически отображаемые в виртуальное адресное пространство ядра
- struct zone; - структура, описывающая зоны
  - zone_lru — голова LRU списка страниц зоны
- struct zone *node_zones; - массив зон памяти

Дескриптор виртуальной памяти процесса

- struct mm_struct;
  - struct vm_area_struct *mmap;
    - Список областей памяти процесса
  - pgd_t *pgd;
    - Каталог виртуальных страниц верхнего уровня
  - atomic_t mm_users;
    - Счетчик использования из других процессов
  - atomic_t mm_count;
    - Основной счетчик использования

Дескриптор области виртуальной памяти

```
struct vm_area_struct {
    unsigned long vm_start;  /* Start address within */
    unsigned long vm_end;    /* The first byte after end */
    struct vm_area_struct *vm_next, *vm_prev;
    /* linked list of VM areas per task, sorted by address */
    struct mm_struct *vm_mm; /* The address space we belong*/
    pgprot_t vm_page_prot;   /* Access permissions of VMA*/
    unsigned long vm_flags;  /* Flags, see mm.h. */
    struct anon_vma *anon_vma;  /* анонимное отображение */
    const struct vm_operations_struct *vm_ops;
    unsigned long vm_pgoff;  /* Offset (within vm_file) */
    struct file * vm_file;   /* File map to (can be NULL)*/
    // …
};
```

Структура адресного пространства

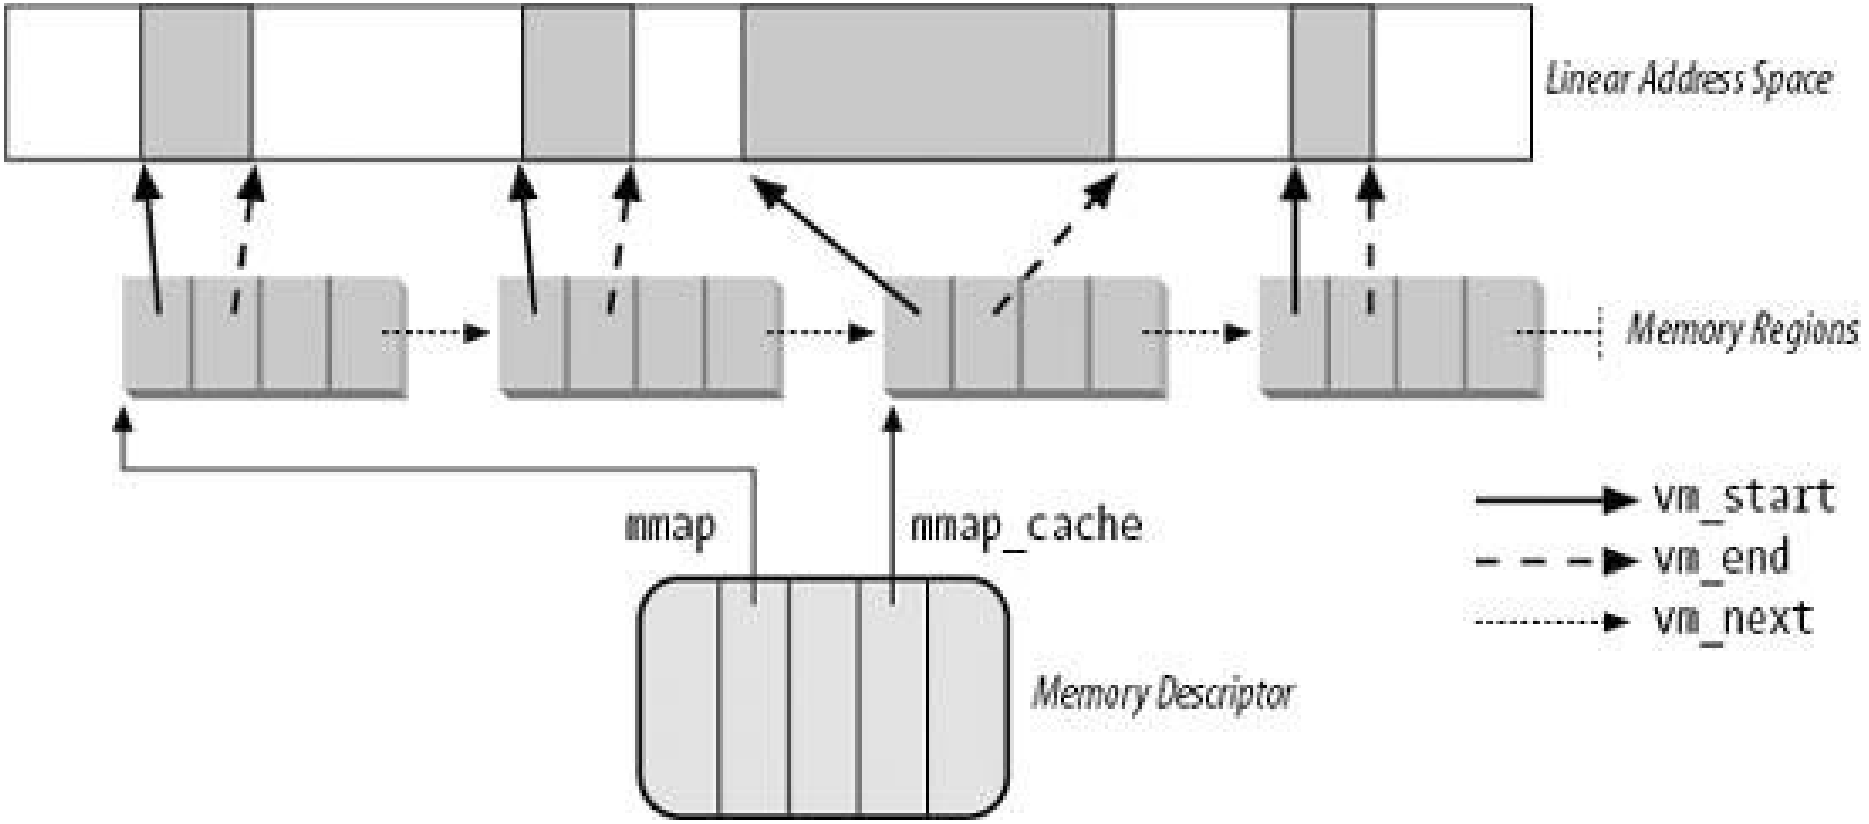

Таблица страниц в процессе

- Поле pgd в struct mm_struct
- Всегда четыре уровня страниц

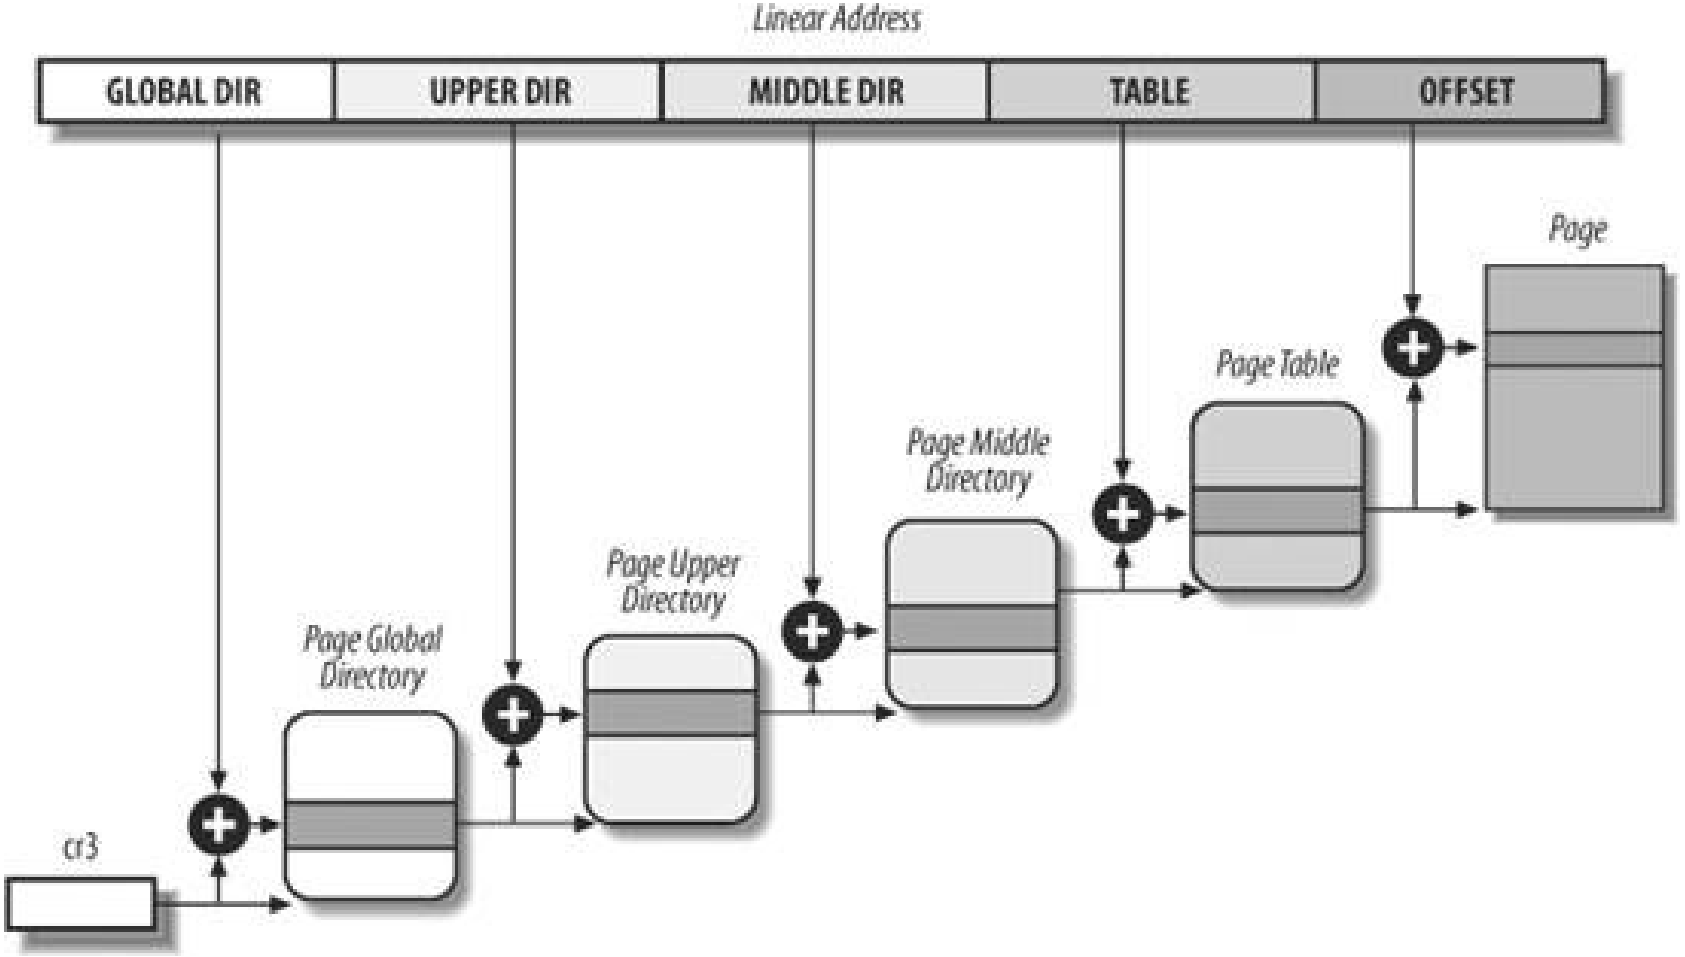

Обратное отображение

- Задача: как внести изменения в структуры процессов при изменениях в состоянии физических страниц?
- У нас есть struct page, требуется найти все PTE процессов, которые ссылаются на эту физическую страницу
- Для анонимных отображений: anon_vma
- Для отображений из файла (mmap): struct address_space

anon_vma

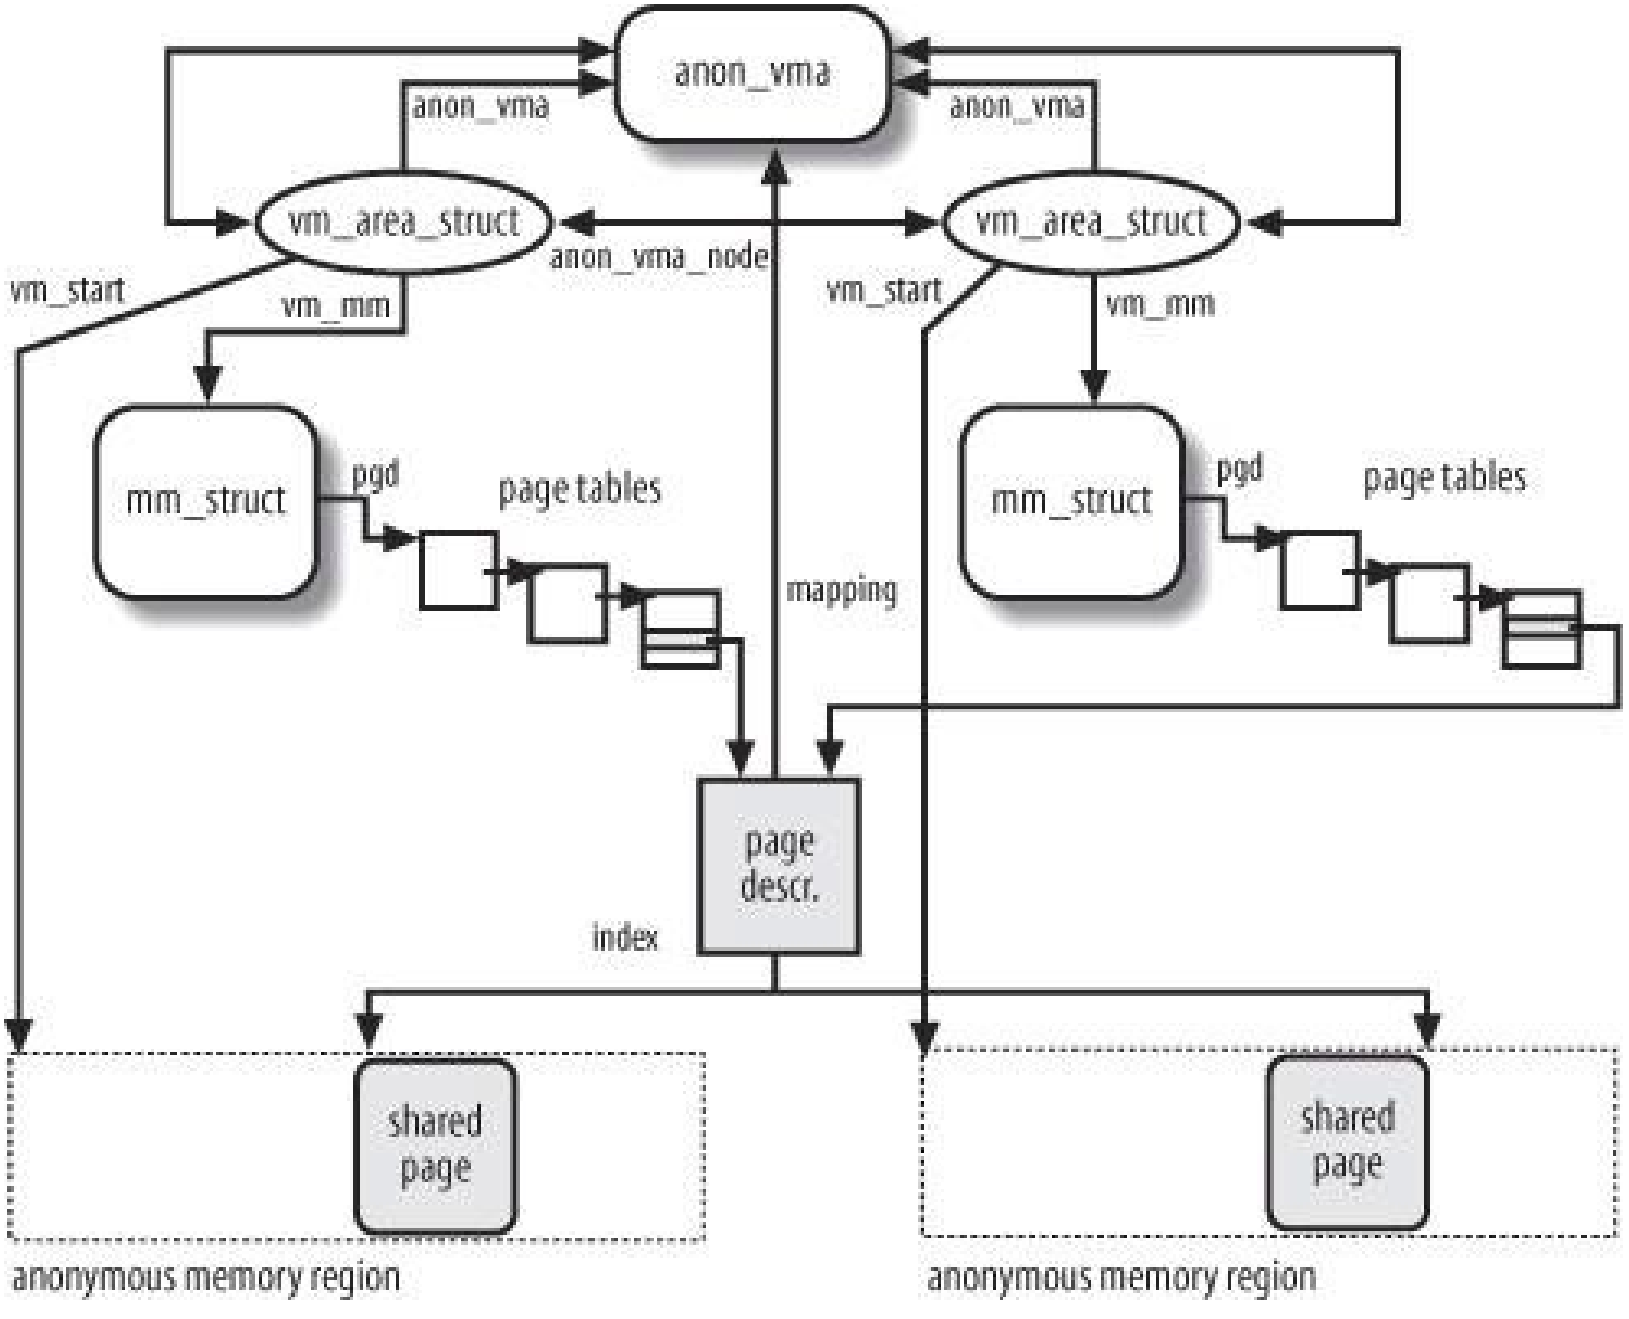
anon_vma
anon_vma
anon_vma
vm_area_struct
anon_vma_node
vm_area_struct
vm_start
vm_mm
vm_start
vm_mm
mm_struct
pgd
page tables
mm_struct
pgd
page tables
mapping
page descr.
index
shared page
shared page
anonymous memory region
anonymous memory region

Struct address_space

```
struct address_space {
  struct inode            *host;     /* owning inode
*/
  struct radix_tree_root  page_tree; /* radix tree of
pages */
  struct prio_tree_root   i_mmap;    /* list of all
mappings*/
  unsigned long           nrpages;   /* total number
of pages */
  pgoff_t                 writeback_index;    /* WB
start off */
  struct address_space_operations   *a_ops;   /* op
table */
  struct backing_dev_info *backing_dev_info;  /* RA
info*/
};
```

Замещение страниц

- Алгоритм замещения страниц должен решить, какую из используемых страниц физической памяти освободить
- Может потребоваться запись в отображаемый файл или swap (для dirty страниц)
- Вызывается при Page Fault, когда нет свободных страниц или их меньше некоторого порога

Состояние страницы

- Для каждой страницы хранится два бита
  - R — из данной страницы было чтение
  - M — страница была модифицирована
- Бит R периодически (например, по таймерному прерыванию) очищается ядром ОС
- Бит M очищается только после записи страницы

Теоретически-оптимальный алг.

- (Алгоритм прорицателя :)
- Выгружается та страница памяти, которая не потребуется в будущем дольше всего
- Например, лучше выгрузить страницу, которая не будет нужна 5 секунд, чем страницу, которая не будет нужна 1 секунду
- Аккуратное предсказание в реальных условиях практически невозможно
- Можно собирать и накапливать информацию о предыдущих запусках, при последующих запусках поведение алгоритма будет приближаться к оптимальному

Not Recently Used

- Пытается удалять неиспользуемую в последнее время страницу (not recently used)
- Страница выбирается случайным образом из множества страниц наименьшего класса
  - (0) R = 0, M = 0
  - (1) R = 1, M = 0
  - (2) R = 0, M = 1
  - (3) R = 1, M = 1

Алгоритм FIFO

- Страницы, загружаемые в память, добавляются в конец очереди
- Выгружается страница из начала очереди
- Алгоритм второй попытки: если к первой в очереди странице было обращение, время загрузки обновляется, страница переставляется в конец списка на удаление

Алгоритм часов (clock)

- Физические страницы организованы в кольцевой список
- «Стрелка» (итератор) указывает на некоторую страницу
- При Page Fault:
  - Если у текущей страницы R == 0, она замещается, стрелка продвигается
  - Если R == 1, R очищается, стрелка продвигается пока не найдется страница с R == 0

Least Recently Used (LRU)

- Выталкивается страница, которая не использовалась дольше всего
- Демонстрирует производительность, близкую к идеальной
- «Настоящий LRU»:
  - при каждом обращении к странице она переставляется в конец списка страниц на выталкивание
  - при выталкивании страница берется из начала
  - очень дорогой и практически не реализуемый!

Two-list LRU (Linux)

- Два списка: активный и неактивный
- Если у страницы R == 1 она перемещается в конец активного списка
- Если активный список становится слишком большим, страницы из начала активного списка перемещаются в конец неактивного списка
- Для вытеснения страницы берутся из головы неактивного списка

Not Frequently Used (NFU)

- При каждом прерывании по таймеру к счетчику использования страницы прибавляется значение R
- Алгоритм старения: предположим, что под счетчик отводится K бит
- Значение счетчика для страницы пересчитывается по формуле:
  count = (count >> 1) | (1 << (K-1))